UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA

RELATÓRIO DE PROJETO DE INICIAÇÃO CIENTÍFICA

MÉTODOS ESPECTRAIS NA SOLUÇÃO DE PROBLEMAS DIRETOS E INVERSOS DO TRANSPORTE DE PARTÍCULAS NEUTRAS

Acadêmico: LEONARDO KAWAI SUAREZ
Orientadora: Profa. Dra. LILIANE BASSO BARICHELLO

Porto Alegre, RS
11 de março de 2026

Conteúdo

1 Introdução **3**

2 Condicionamento de Matrizes **4**

3 Eliminação Gaussiana e Fatoração LU **7**
3.1 Eliminação Gaussiana com Pivotamento Parcial 7
3.2 Fatoração LU para resolver $A\mathbf{x_i} = \mathbf{b_i}$ 7
3.3 Estabilidade da Eliminação Gaussiana 8

4 Métodos Iterativos **9**
4.1 Método de Jacobi 9
4.2 Método de Gauss-Seidel 9
4.3 Iteração SOR 10
4.4 Convergência dos Métodos Iterativos 10
4.5 Análise dos Métodos Iterativos 11

1 Introdução

Este relatório documenta os estudos iniciais do projeto de iniciação científica intitulado *Métodos Espectrais na Solução de Problemas Diretos e Inversos do Transporte de Partículas Neutras*, utilizando como referência base o livro *Numerical Linear Algebra with Applications* de William Ford [1]. A pesquisa começou pela análise de condicionamento numérico e estabilidade de algoritmos, com foco em matrizes mal-condicionadas como as de Hilbert e Toeplitz.

Em seguida, investigamos métodos diretos para a resolução de sistemas lineares, incluindo a tradicional eliminação gaussiana (sem e com pivotamento parcial) e a fatoração LU, comparando seu desempenho. Posteriormente, estudamos métodos iterativos básicos (Jacobi, Gauss-Seidel e SOR), aplicados à equação de Poisson unidimensional discretizada, juntamente com a análise de convergência desses métodos.

Estes resultados fornecem a base necessária para o desenvolvimento posterior de métodos espectrais mais sofisticados para problemas envolvendo a equação de transporte de Boltzmann.

2 Condicionamento de Matrizes

Para além dos conhecimentos elementares adquiridos em um primeiro curso de Álgebra Linear, como a resolução de sistemas lineares via eliminação gaussiana, a determinação dos autovalores e autovetores de uma matriz, e a diagonalização de matrizes simétricas, é crucial compreender as limitações da computação numérica. A precisão dos resultados computacionais é frequentemente afetada por erros de arredondamento, que podem ser exacerbados por algoritmos instáveis ou problemas mal-condicionados.

Definição 2.1. Um problema é dito *mal-condicionado* se pequenas perturbações nos dados de entrada podem levar a grandes variações na solução. Em contraste, um problema é *bem-condicionado* se pequenas perturbações nos dados de entrada resultam em pequenas variações na solução.

Teorema 2.1. *Suponha que A é uma matriz não-singular, $\mathbf{b} \neq 0$ é um vetor, $\mathbf{x}$ é a solução do sistema $A\mathbf{x} = \mathbf{b}$, e $\|\cdot\|$ é uma norma subordinada.*

1. *Se $\mathbf{x} + \delta\mathbf{x}$ é a solução do sistema perturbado $A(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b} + \delta\mathbf{b}$, então*

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\| \left\|A^{-1}\right\| \frac{\|\delta\mathbf{b}\|}{\|\mathbf{b}\|}. \tag{1}$$

2. *Se $\mathbf{x} + \delta\mathbf{x}$ é a solução do sistema perturbado $(A + \delta A)(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b}$, então*

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x} + \delta\mathbf{x}\|} \leq \|A\| \left\|A^{-1}\right\| \frac{\|\delta A\|}{\|A\|}. \tag{2}$$

3. *Se $\mathbf{x} + \delta\mathbf{x}$ é a solução do sistema perturbado $(A + \delta A)(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b} + \delta\mathbf{b}$, então*

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A\| \left\|A^{-1}\right\| \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta\mathbf{b}\|}{\|A\| \, \|\mathbf{x} + \delta\mathbf{x}\|} \right). \tag{3}$$

Definição 2.2. O número de condicionamento de uma matriz A é definido como $\kappa(A) = \|A\| \cdot \|A^{-1}\|$. Este número fornece uma medida da sensibilidade da solução de um sistema linear $A\mathbf{x} = \mathbf{b}$ a perturbações na matriz A e no vetor $\mathbf{b}$.

Exemplo 2.3. Considere o seguinte sistema linear [2]:

$$\begin{cases} 0.835x_1 + 0.667x_2 = 0.168 \\ 0.333x_1 + 0.266x_2 = 0.067 \end{cases}$$

que possui solução $\mathbf{x} = \begin{bmatrix} 1 & -1 \end{bmatrix}^T$. Perturbamos o vetor $\mathbf{b} = \begin{bmatrix} 0.168 & 0.067 \end{bmatrix}^T$ para $\mathbf{b} + \delta\mathbf{b} = \begin{bmatrix} 0.168 & 0.066 \end{bmatrix}^T$. Nota que a perturbação relativa $\|\delta\mathbf{b}\|/\|\mathbf{b}\| = 0.0055289$ é pequena, então seria razoável esperar que a solução perturbada $\mathbf{x} + \delta\mathbf{x}$ também fosse próxima de $\mathbf{x}$. No entanto, a solução do sistema perturbado é $\mathbf{x} + \delta\mathbf{x} = \begin{bmatrix} 666 & -834 \end{bmatrix}^T$.

A perturbação relativa na solução $\|\delta\mathbf{x}\|/\|\mathbf{x}\|$ é aproximadamente 753.7, indicando que o sistema é mal-condicionado, conforme (1). De fato, o número de condicionamento da matriz A é $\kappa(A) = 1323759$. Isso mostra que apesar de o resíduo relativo $\|\delta\mathbf{b}\|/\|\mathbf{b}\|$ ser pequeno, a solução computada $\mathbf{x} + \delta\mathbf{x}$ pode ser drasticamente diferente de $\mathbf{x}$ devido ao alto número de condicionamento da matriz A.

Problema 2.4. As matrizes de Hilbert são matrizes $n \times n$ com elementos $h_{ij} = 1/(i + j - 1)$ e são notoriamente mal-condicionadas.

(a) Construímos a matriz de Hilbert A de ordem $n = 8$ através do comando `hilbm(8)`. Perturbamos $A(1, 8)$ por 10^{-5} e definimos a matriz perturbada B. Seja `b = rand(8,1)`. Computamos as soluções `x = A\b`, `y = B\b` e seguimos calculando $\|\mathbf{x} - \mathbf{y}\|$ e $\|\mathbf{x} - \mathbf{y}\|/\|\mathbf{x}\|$.

```
A = hilbm(8);
B = A;
B(1,8) = B(1,8) + 1e-5;
b = rand(8,1);
x = A\b;
y = B\b;
```

```
  norm(x-y);
  norm(x-y)/norm(x);

--> norm(x-y)
ans =

  1.650D+09

--> norm(x-y)/norm(x)
ans =

  1.2164185
```

Os valores da perturbação $\|\mathbf{x}-\mathbf{y}\|$ e da perturbação relativa $\|\mathbf{x}-\mathbf{y}\|/\|\mathbf{x}\|$ da solução são altos, indicando mal-condicionamento da matriz A, de acordo com (1)

(b) Podemos agora verificar a cota superior na desigualdade de condicionamento de (2).

```
  --> norm(x-y)/norm(y) <= cond(A)*norm(A-B)/norm(A)
ans =

  T
```

Problema 2.5. Uma matriz de Toeplitz é uma matriz $n \times n$ cujas entradas são constantes ao longo de cada diagonal. O comando Scilab `toeplitz(c,r)` constrói uma matriz de Toeplitz com o vetor **c** como a primeira coluna e o vetor **r** como a primeira linha. Se os primeiros elementos de **c** e **r** forem diferentes, uma mensagem é exibida e o elemento da coluna é usado como o primeiro elemento da primeira linha.

(a) Construímos a matriz 100×100 pentadiagonal abaixo

$$T = \begin{bmatrix} 6 & -4 & 1 & 0 & \dots & 0 \\ -4 & 6 & -4 & 1 & \dots & 0 \\ 1 & -4 & 6 & -4 & \dots & 0 \\ 0 & 1 & -4 & 6 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 6 \end{bmatrix}$$

```
c = [6, -4, 1, zeros(1, 97)];
T = toeplitz(c');

  --> cond(T)

ans =

  3457869.2
```

(b) Nota que cond(A) é da ordem de 10^6, sugerindo mal-condicionamento da matriz.

(c) Fazemos um experimento para observar o comportamento dos autovalores da matriz T ao perturbar suas entradas. O seguinte programa computa os autovalores de uma matriz T aleatoriamente perturbada. Nesse caso, as perturbações estão no intervalo $0 < a_{ij} < 10^{-8}$.

```
E1 = spec(T);
E1 = gsort(E1);
```

```
for i = 1:3
  deltaT = 1e-8 * rand(100, 100);
  B = T + deltaT;
  E2 = spec(B);
  E2 = gsort(E2);
  norm(E1 - E2)
end

0.0000004
0.0000004
0.0000004
```

Todas as três iterações produziram o mesmo resultado (4×10^{-7}), que é relativamente proporcional ao grau de perturbação ($\approx 10^{-8}$) indicando que os autovalores da matriz T são bem-condicionados. Isso sugere que, apesar de a matriz T ser mal-condicionada, os autovalores não são sensíveis a pequenas perturbações.

3 Eliminação Gaussiana e Fatoração LU

Em diversas aplicações onde aparecem sistemas lineares, é necessário resolver $A\mathbf{x} = \mathbf{b}$ para muitos vetores $\mathbf{b}$, como no exemplo de uma viga que está sujeita a suportar diferentes cargas. A eliminação gaussiana é um método prático para resolver esses sistemas, mas pode ser computacionalmente caro se for necessário resolver muitos sistemas com a mesma matriz A. A decomposição LU é uma técnica que permite fatorar a matriz A em duas matrizes triangulares, L e U, de forma que $A = LU$. Isso possibilita resolver múltiplos sistemas lineares com a mesma matriz A de maneira mais eficiente.

Em resumo, o método consiste em realizar a eliminação gaussiana para transformar a matriz A em uma matriz triangular superior U, enquanto armazena os multiplicadores das operações de eliminação em uma matriz triangular inferior L, que possui elementos da diagonal principal iguais a 1. Assim, a solução do sistema $A\mathbf{x} = (LU)\mathbf{x} = \mathbf{b}$ pode ser obtida resolvendo primeiro $L\mathbf{y} = \mathbf{b}$ (*forward substitution*) e, em seguida, $U\mathbf{x} = \mathbf{y}$ (*backward substitution*).

3.1 Eliminação Gaussiana com Pivotamento Parcial

A eliminação gaussiana pode produzir resultados imprecisos, conforme mostra o exemplo a seguir.

Exemplo 3.1. Considere a matriz abaixo

$$A = \begin{bmatrix} 0.00001 & 3 \\ 2 & 1 \end{bmatrix}$$

e use precisão aritmética de três dígitos significativos. Prosseguindo com a decomposição LU, temos:

$$L = \begin{bmatrix} 1 & 0 \\ 200000 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 0.00001 & 3 \\ 0 & -599999 \end{bmatrix}.$$

Na aritmética de três dígitos significativos, U torna-se:

$$U = \begin{bmatrix} 0.00001 & 3 \\ 0 & -600000 \end{bmatrix}.$$

Computamos LU para obter

$$LU = \begin{bmatrix} 0.00001 & 3 \\ 2 & 0 \end{bmatrix},$$

que é muito diferente de A.

Do exemplo acima, observa-se que a eliminação gaussiana pode produzir péssimos resultados em certas situações, especialmente quando algum elemento pivô é pequeno, levando a erros de arredondamento significativos em aritmética de ponto flutuante. Para evitar isso, é comum utilizar a estratégia de pivotamento parcial (GEPP), que consiste em trocar linhas para garantir que o maior elemento possível seja escolhido como pivô. Isso melhora a estabilidade numérica do método.

Na eliminação gaussiana com pivotamento parcial, o algoritmo é modificado para incluir uma etapa de busca do maior elemento na coluna atual antes de realizar a eliminação. A decomposição LU com pivotamento parcial consiste então em três matrizes P, L e U. A relação entre essas matrizes é dada por:

$$PA = LU \tag{4}$$

onde P é a matriz de permutação, ou matriz de pivotamento. Comece com $P = I$ e troque as linhas i e j da matriz de permutação sempre que as linhas i e j são trocadas na eliminação gaussiana.

3.2 Fatoração LU para resolver $A\mathbf{x_i} = \mathbf{b_i}$

Para resolver um sistema $A\mathbf{x_i} = \mathbf{b_i}$, $1 \leq i \leq k$, multiplique ambos os lados pela esquerda por P:

$$PA\mathbf{x_i} = P\mathbf{b_i}. \tag{5}$$

Seja $\overline{\mathbf{b}} = P\mathbf{b_i}$ e substitua PA por LU:

$$LU\mathbf{x} = \overline{\mathbf{b}}. \tag{6}$$

E resolva por substituição:

$$L\mathbf{y} = \overline{\mathbf{b}} \quad \text{(forward substitution)}, \tag{7}$$
$$U\mathbf{x} = \mathbf{y} \quad \text{(backward substitution)}. \tag{8}$$

O custo da decomposição LU é $O(n^3)$, e o custo de resolver k sistemas lineares é $O(kn^2)$. Se tivéssemos que resolver k sistemas lineares com eliminação gaussiana, o custo seria $O(kn^3)$. Portanto, a decomposição LU é vantajosa quando k é grande, pois reduz o custo computacional total.

3.3 Estabilidade da Eliminação Gaussiana

A eliminação gaussiana sem pivotamento parcial não é estável em geral, como mostrado anteriormente. Ainda é possível, em teoria, que o algoritmo GEPP seja instável em certas matrizes. Entretanto, essas matrizes nunca foram encontradas em aplicações, então consideramos o método estável na prática.

Definição 3.2. Aplique a fatoração LU para a matriz A. Durante a eliminação, temos as matrizes $A = A^{(0)}, A^{(1)}, A^{(2)}, \ldots, A^{(n-1)} = U$. O fator de crescimento é definido como

$$\rho = \frac{\max_{i,j,k} |a_{ij}^{(k)}|}{\max_{i,j} |a_{ij}|}; \tag{9}$$

isto é, é a razão entre o maior elemento em magnitude durante a eliminação gaussiana e o maior elemento da matriz A.

Exemplo 3.3. Calculamos o fator de crescimento da matriz do exemplo 3.1 nos dois casos. Sem pivotamento parcial:

$$\begin{bmatrix} 0.00001 & 3 \\ 2 & 1 \end{bmatrix} \sim \begin{bmatrix} 0.00001 & 3 \\ 0 & -599999 \end{bmatrix}.$$

e o fator de crescimento é $\rho = \frac{599999}{3} = 199999.67$.

Com pivotamento parcial:

$$\begin{bmatrix} 0.00001 & 3 \\ 2 & 1 \end{bmatrix} \sim \begin{bmatrix} 2 & 1 \\ 0.00001 & 3 \end{bmatrix} \sim \begin{bmatrix} 2 & 1 \\ 0 & 2.999995 \end{bmatrix}$$

e $\rho = \frac{3}{3} = 1$.

Teorema 3.1. *Seja $PA = LU$ a fatoração da matriz A via eliminação gaussiana. Então, as matrizes computadas $\tilde{L}, \tilde{U}$, e $\tilde{P}$ satisfazem*

$$\tilde{L}\tilde{U} = \tilde{P}A + \delta A \qquad \frac{\|\delta A\|_2}{\|A\|} = O(\rho\ eps) \tag{10}$$

para uma matriz δA $n \times n$, onde ρ é o fator de crescimento de A. Se $|l_{ij}| < 1$ para todo $i > j$, implicando que não há empates na seleção de pivôs em aritmética exata, então $\tilde{P} = P$ para todo eps suficientemente pequeno.

4 Métodos Iterativos

Problemas que envolvem matrizes grandes surgem na discretização de equações diferenciais parciais e em aplicações como design e análise de circuitos elétricos e processos de engenharia química. Frequentemente, esses sistemas lineares são esparsos, ou seja, muitas das entradas da matriz correspondente são zero. Conforme visto na seção anterior, a eliminação gaussiana em aritmética de ponto flutuante pode transformar zeros em números não-nulos e, assim, destruir a esparsidade da matriz. Então, para matrizes grandes e esparsas, costuma-se utilizar métodos iterativos. Um método iterativo é um algoritmo que gera uma sequência de aproximações para a solução de um sistema linear $A\mathbf{x} = \mathbf{b}$. A ideia é começar com uma aproximação inicial $\mathbf{x}^{(0)}$ e, em cada iteração, melhorar essa aproximação até que a solução computada convirja para a solução exata $\mathbf{x}$, fornecidos uma tolerância e um número máximo de iterações. Na seção seguinte, apresentamos três métodos iterativos populares: Jacobi, Gauss-Seidel e SOR (Successive Over-Relaxation).

4.1 Método de Jacobi

O método de Jacobi é um dos métodos iterativos mais simples. Reescrevemos o sistema $A\mathbf{x} = \mathbf{b}$ de forma que cada variável x_i seja isolada em termos das outras variáveis. O sistema pode ser escrito como:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \ldots + a_{1n}x_n &= b_1, \\ a_{21}x_1 + a_{22}x_2 + \ldots + a_{2n}x_n &= b_2, \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \ldots + a_{nn}x_n &= b_n. \end{aligned}$$

A iteração é então definida como:

$$x_i = \frac{1}{a_{ii}} \left[b_i - \left(\sum_{j=1, j\neq i}^{n} a_{ij}x_j \right) \right], \quad 1 \leq i \leq n. \tag{11}$$

As iterações de Jacobi podem ser escritas na forma matricial:

$$\mathbf{x}^{(k)} = B_J\mathbf{x}^{(k-1)} + \mathbf{c}_J, \tag{12}$$

onde

$$B_J = -D^{-1}(L+U), \quad \mathbf{c}_J = D^{-1}\mathbf{b}. \tag{13}$$

4.2 Método de Gauss-Seidel

A iteração de Gauss-Seidel é uma modificação do método de Jacobi. A ideia é usar a solução mais recente disponível para atualizar as variáveis imediatamente, em vez de esperar até a próxima iteração. A iteração de Gauss-Seidel é definida como:

$$x_i^{(k)} = \frac{1}{a_{ii}} \left[b_i - \left(\sum_{j=1}^{i-1} a_{ij}x_j^{(k)} + \sum_{j=i+1}^{n} a_{ij}x_j^{(k-1)} \right) \right], \quad i = 2, 3, \ldots, n-1. \tag{14}$$

As iterações de Gauss-Seidel podem ser escritas na forma matricial:

$$\mathbf{x}^{(k)} = B_{GS}\mathbf{x}^{(k-1)} + \mathbf{c}_{GS}, \tag{15}$$

onde

$$B_{GS} = -(D+L)^{-1}U, \quad \mathbf{c}_{GS} = (D+L)^{-1}\mathbf{b}. \tag{16}$$

4.3 Iteração SOR

A iteração SOR (Successive Over-Relaxation) é uma generalização do método de Gauss-Seidel que introduz um fator de relaxação ω para acelerar a convergência. Tem como princípio ajustar a atualização de cada variável x_i com um fator ω:

$$x_i^{(k)} = (1-\omega)x_i^{(k-1)} + \frac{\omega}{a_{ii}}\left[b_i - \left(\sum_{j=1}^{i-1} a_{ij}x_j^{(k)} + \sum_{j=i+1}^{n} a_{ij}x_j^{(k-1)}\right)\right], \quad i = 2, 3, \ldots, n-1. \tag{17}$$

A iteração SOR pode ser escrita na forma matricial:

$$\mathbf{x}^{(k)} = B_{SOR}\mathbf{x}^{(k-1)} + \mathbf{c}_{SOR}, \tag{18}$$

onde

$$B_{SOR} = (D+\omega L)^{-1}((1-\omega)D - \omega U), \quad \mathbf{c}_{SOR} = (D+\omega L)^{-1}\mathbf{b}. \tag{19}$$

4.4 Convergência dos Métodos Iterativos

Listamos abaixo alguns teoremas que garantem a convergência dos métodos iterativos discutidos anteriormente.

Teorema 4.1. *Se a matriz B na iteração $\mathbf{x}^{(k)} = B\mathbf{x}^{(k-1)} + \mathbf{c}$ tem a propriedade de que $\|B\| < 1$ para alguma norma subordinada, então a iteração converge para qualquer escolha de aproximação inicial $\mathbf{x}^{(0)}$.*

Teorema 4.2. *A iteração $\mathbf{x}^{(k+1)} = B\mathbf{x}^{(k)} + \mathbf{c}$ converge se e somente se $\rho(B) < 1$, onde $\rho(B)$ é o raio espectral de B.*

Teorema 4.3. *Se A é uma matriz estritamente diagonal dominante, então o método de Jacobi converge para qualquer escolha de aproximação inicial $\mathbf{x}^{(0)}$.*

Teorema 4.4. *Seja A uma matriz simétrica positiva definida. Para qualquer escolha de aproximação inicial $\mathbf{x}^{(0)}$, o método de Gauss-Seidel converge.*

Teorema 4.5. *Se a iteração SOR converge para qualquer aproximação inicial $\mathbf{x}^{(0)}$, então $0 < \omega < 2$.*

Teorema 4.6. *Se A é uma matriz simétrica positiva definida e $0 < \omega < 2$, então as iterações SOR e Gauss-Seidel convergem para qualquer escolha de aproximação inicial $\mathbf{x}^{(0)}$.*

Problema 4.1. (a) Dada a equação de Poisson unidimensional

$$-\frac{d^2u}{dx^2} = f(x), \quad 0 \le x \le 1, \tag{20}$$

com condições de contorno $u_1 = 0$ e $u_{n+1} = 0$, e a aproximação por diferenças finitas para a segunda derivada:

$$\frac{d^2u}{dx^2}(x_i) \approx \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}, \tag{21}$$

o sistema de equações pode ser escrito na forma matricial $A\mathbf{x} = \mathbf{b}$, onde:

$$A = \frac{1}{h^2}\begin{bmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -1 & 2 & -1 \\ 0 & \cdots & 0 & -1 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} f(x_2) \\ f(x_3) \\ \vdots \\ f(x_{n-1}) \\ f(x_n) \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} u_2 \\ u_3 \\ \vdots \\ u_{n-1} \\ u_n \end{bmatrix}.$$

(b) Para mostrar que A é positiva definida, demonstramos que $\mathbf{x}^T A\mathbf{x} > 0$ para todo $\mathbf{x} \neq \mathbf{0}$.

$$\begin{aligned}
\mathbf{x}^T A\mathbf{x} &= \frac{1}{h^2}\sum_{i=1}^{n}\left(2x_i^2 - 2x_i x_{i+1}\right) \quad (\text{com } x_0 = x_{n+1} = 0) \\
&= \frac{1}{h^2}\left(\sum_{i=1}^{n} x_i^2 + \sum_{i=1}^{n}(x_i^2 - 2x_i x_{i+1} + x_{i+1}^2)\right) \\
&= \frac{1}{h^2}\left(\sum_{i=1}^{n} x_i^2 + \sum_{i=1}^{n}(x_i - x_{i+1})^2\right) > 0 \quad \text{para } \mathbf{x} \neq \mathbf{0}.
\end{aligned}$$

A soma é estritamente positiva pois $\sum x_i^2 \geq 0$ e $\sum(x_i - x_{i+1})^2 \geq 0$.

Portanto, A é positiva definida e, pelo Teorema 4.4, a iteração Gauss-Seidel converge para a solução do sistema $A\mathbf{x} = \mathbf{b}$.

4.5 Análise dos Métodos Iterativos

A partir do problema anterior, realizamos uma análise dos métodos iterativos Jacobi, Gauss-Seidel e SOR (Successive Over-Relaxation) no software Scilab.

Para $n = 50$ e $f(x) = 1$, construímos a matriz A e o vetor $\mathbf{b}$ conforme o item (a). Os resultados dos métodos iterativos Jacobi, Gauss-Seidel e SOR (com $\omega = 1.3$) são apresentados a seguir.

```
              +-----------------------------------------+
              |          ANÁLISE MÉTODO DE JACOBI       |
              +-----------------------------------------+
              | Norma      | Valor      | Convergência  |
              +-----------------------------------------+
              | Norma-1    | 1.000000   | Não           |
              | Norma-2    | 0.998103   | Sim           |
              | Norma-Inf  | 1.000000   | Não           |
              +-----------------------------------------+
Convergência: ao menos uma norma é < 1, sugerindo convergência.

Raio espectral: 0.998103 (< 1 garante convergência)


              +-----------------------------------------+
              |      ANÁLISE MÉTODO DE GAUSS-SEIDEL     |
              +-----------------------------------------+
              | Norma     | Valor      | Convergência   |
              +-----------------------------------------+
              | Norma-1    | 1.000000   | Sim           |
              | Norma-2    | 0.996324   | Sim           |
              | Norma-Inf  | 1.000000   | Sim           |
              +-----------------------------------------+
Convergência: ao menos uma norma é < 1, sugerindo convergência.

Raio espectral: 0.996210 (< 1 garante convergência)

              +-----------------------------------------+
              |            ANÁLISE MÉTODO SOR           |
              |            (omega = 1.3000)             |
              +-----------------------------------------+
              | Norma      | Valor      | Convergência  |
              +-----------------------------------------+
              | Norma-1    | 1.000000   | Sim           |
              | Norma-2    | 0.995344   | Sim           |
```

```
              | Norma-Inf  | 1.000000   | Sim            |
              +-----------------------------------------+
Convergência: ao menos uma norma é < 1, sugerindo convergência.

Raio espectral: 0.992957 (< 1 garante convergência)

              +-----------------------------------------------+
              |           COMPARAÇÃO DOS RESULTADOS           |
              +-----------------------------------------------+
              | Método       | Raio espectral  | Melhor opção|
              +-----------------------------------------------+
              | Jacobi       | 0.998103        | Não         |
              | Gauss-Seidel | 0.996210        | Não         |
              | SOR (w=1.30) | 0.992957        | Sim         |
              +-----------------------------------------------+

======================================================================
                    RESULTADOS DOS MÉTODOS ITERATIVOS
======================================================================
Matriz: 50x50  | Tolerância: 1.0e-06      | SOR omega: 1.30

Método         | Iterações  | Resíduo     | Tempo(s)   | Raio espectral
----------------------------------------------------------------------
Jacobi         |        5000 |     6.86e-05 |   71.5857 |     0.9981
Gauss-Seidel   |        3615 |     9.98e-07 |   38.9605 |     0.9962
SOR            |        1944 |     9.95e-07 |   21.3000 |          -
======================================================================
```

Referências

[1] William Ford. *Numerical Linear Algebra with Applications*. Elsevier, 2015.

[2] Carl Meyer. *Matrix Analysis and Applied Linear Algebra*. SIAM, 2000.